

Dokumentacja projektu Big Data

System analityczny do analizy ogłoszeń o zaginionych i odnalezionych zwierzętach domowych

Temat	Analiza ogłoszeń dotyczących zaginięcia i odnalezienia zwierząt domowych
Zakres techniczny	Web scraping, CSV, czyszczenie danych, SQLite, SQL, Excel
Liczba rekordów	240 ogłoszeń

1. Temat projektu

Projekt systemu analitycznego do analizy ogłoszeń dotyczących zaginięcia i odnalezienia zwierząt domowych na podstawie danych pozyskanych z publicznych źródeł internetowych.

2. Cel projektu

Celem projektu jest zaprojektowanie i wykonanie niewielkiego systemu analitycznego, który umożliwia pozyskiwanie, porządkowanie, przetwarzanie oraz analizę danych dotyczących ogłoszeń o zaginionych i odnalezionych zwierzętach domowych.

System został przygotowany w taki sposób, aby obejmował pełny proces pracy z danymi: od pobrania informacji ze źródła internetowego, przez zapis danych surowych, oczyszczanie i standaryzację, aż po utworzenie warstwy wynikowej w postaci tabel analitycznych, zapytań SQL oraz raportu w pliku Excel.

Projekt ma na celu pokazanie, w jaki sposób dane publikowane w serwisach internetowych mogą zostać przekształcone w uporządkowany zbiór danych nadający się do dalszej analizy. Na podstawie przygotowanych danych możliwe jest m.in. sprawdzenie liczby ogłoszeń według gatunku zwierzęcia, województwa, miejscowości, informacji o nagrodzie, typu ogłoszenia oraz jakości opisów.

3. Założenia projektu

W projekcie przyjęto założenie, że dane wejściowe będą pochodziły z publicznie dostępnego serwisu internetowego zawierającego ogłoszenia dotyczące zaginionych zwierząt. Dane zostały pozyskane automatycznie przy pomocy skryptu napisanego w języku Python.

Zakres projektu obejmuje następujące elementy:

- pobranie danych z publicznego źródła internetowego;
- zapis danych surowych do pliku CSV;
- oczyszczenie i standaryzację danych;

- ▷ utworzenie dodatkowych cech analitycznych;
- ▷ zapis oczyszczonych danych do osobnego pliku CSV;
- ▷ utworzenie relacyjnej bazy danych SQLite;
- ▷ załadowanie oczyszczonych danych do tabeli w bazie danych;
- ▷ wykonanie zapytań SQL;
- ▷ przygotowanie tabel wynikowych;
- ▷ przygotowanie raportu w pliku Excel.

W projekcie zastosowano podejście warstwowe. Dane surowe zostały potraktowane jako warstwa Bronze, dane oczyszczone jako warstwa Silver, natomiast tabele wynikowe oraz wyniki zapytań SQL jako warstwa Gold.

Przyjęto również założenie, że dane pochodzące ze stron internetowych mogą być niejednorodne i częściowo nieustrukturyzowane. Z tego powodu ważną częścią projektu jest etap czyszczenia danych, obejmujący m.in. normalizację nazw pól, usuwanie zbędnych fragmentów tekstu, uzupełnianie cech analitycznych oraz kontrolę kompletności rekordów.

4. Źródło danych

Dane wykorzystane w projekcie zostały pobrane z publicznie dostępnego serwisu internetowego alertuj-ogloszenia.pl, który zawiera ogłoszenia dotyczące zaginionych zwierząt. Serwis udostępnia listę ogłoszeń oraz podstrony szczegółowe, na których znajdują się informacje opisowe o zwierzęciu i miejscu zaginięcia.

W ramach projektu pobrano 20 stron listy ogłoszeń. Po usunięciu duplikatów adresów URL uzyskano 240 unikalnych rekordów. Każdy rekord odpowiada jednemu ogłoszeniu pobranemu z podstrony szczegółowej.

Zakres pozyskiwanych informacji obejmował następujące pola:

- ▷ tytuł ogłoszenia;
- ▷ adres URL ogłoszenia;
- ▷ kategorię ogłoszenia;
- ▷ typ ogłoszenia;
- ▷ datę publikacji;
- ▷ gatunek zwierzęcia;
- ▷ imię zwierzęcia;
- ▷ województwo / region;
- ▷ miejscowość;
- ▷ informację o nagrodzie;
- ▷ opis ogłoszenia.

Dane zostały wykorzystane wyłącznie w celach edukacyjnych i analitycznych. Projekt nie koncentruje się na danych osobowych autorów ogłoszeń, dlatego podczas przygotowania danych usuwano lub pomijano elementy kontaktowe, które nie były potrzebne do analizy.

5. Architektura systemu

System został zaprojektowany jako prosty proces analityczny obejmujący kilka kolejnych etapów pracy z danymi. Każdy etap odpowiada za inną część przetwarzania: od pobrania danych, przez czyszczenie i zapis w bazie danych, aż po utworzenie warstwy wynikowej.

Ogólny przepływ danych w projekcie można przedstawić w następujący sposób:

- publiczne źródło internetowe
- skrypt Python pobierający dane
- plik CSV z danymi surowymi
- plik CSV z danymi oczyszczonymi
- relacyjna baza danych SQLite
- zapytania SQL
- tabele wynikowe CSV
- raport końcowy Excel

Takie podejście pozwala oddzielić dane surowe od danych oczyszczonych i wynikowych. Dzięki temu można łatwiej kontrolować poprawność przetwarzania, powtarzać wybrane etapy oraz porównywać dane przed i po czyszczeniu.

6. Struktura warstw projektu

W projekcie zastosowano strukturę warstwową, która porządkuje kolejne etapy pracy z danymi. Takie podejście jest często stosowane w systemach analitycznych, ponieważ pozwala jasno rozdzielić dane wejściowe, dane przetworzone oraz dane wynikowe.

Warstwa	Pliki / elementy	Rola w projekcie
Bronze	alertuj_ogloszenia_raw.csv	Dane surowe pobrane ze strony internetowej, zapisane bez pogłębionej analizy.
Silver	alertuj_ogloszenia_clean.csv	Dane oczyszczone i wzbogacone o dodatkowe cechy analityczne.
SQL	pet_announcements.db	Relacyjna baza danych SQLite zawierająca oczyszczone rekordy.
Gold	gold_*.csv, sql_*.csv	Tabele wynikowe przygotowane na potrzeby analizy i raportowania.
Prezentacja wyników	big_data_pet_announcements_report.xlsx	Raport Excel zawierający dane, tabele oraz wykresy.

7. Technologie użyte w projekcie

Do realizacji projektu wykorzystano zestaw narzędzi umożliwiających pobranie danych ze strony internetowej, ich przetworzenie, zapisanie w uporządkowanej formie oraz przygotowanie wyników analitycznych.

Technologia	Zastosowanie w projekcie
Python	Główny język użyty do pobierania, przetwarzania i zapisywania danych.
requests	Biblioteka wykorzystana do pobierania kodu HTML stron internetowych.
BeautifulSoup	Narzędzie użyte do parsowania HTML i wyodrębniania informacji z ogłoszeń.
CSV	Format zapisu danych surowych, oczyszczonych oraz tabel wynikowych.
SQLite	Relacyjna baza danych wykorzystana do przechowywania oczyszczonych rekordów.
SQL	Język zapytań użyty do przygotowania zestawień analitycznych.
Excel	Warstwa raportowa wykorzystywana do prezentacji tabel i wykresów.
openpyxl	Biblioteka Python użyta do automatycznego utworzenia raportu Excel.

Zastosowany zestaw technologii pozwolił przygotować kompletny proces ETL: pobranie danych, ich transformację, zapis w bazie danych oraz wygenerowanie warstwy wynikowej.

8. Proces pobierania danych

Pobieranie danych zostało wykonane przy pomocy skryptu Python. Skrypt przechodził po kolejnych stronach listy ogłoszeń, pobierał linki do szczegółowych podstron, usuwał duplikaty adresów URL, a następnie pobierał informacje z każdego ogłoszenia.

Proces pobierania danych obejmował następujące kroki:

- ▷ utworzenie adresów URL kolejnych stron listy ogłoszeń;
- ▷ pobranie kodu HTML każdej strony listy;
- ▷ wyszukanie linków prowadzących do szczegółowych ogłoszeń;
- ▷ usunięcie duplikatów linków;
- ▷ pobranie każdej podstrony ogłoszenia;
- ▷ wyodrębnienie pól takich jak tytuł, data, gatunek, region, miejscowość, nagroda i opis;
- ▷ zapis wyników do pliku alertuj_ogloszenia_raw.csv.

W trakcie pobierania danych zastosowano krótką przerwę między kolejnymi żądaniami. Miało to na celu ograniczenie liczby zapytań wysyłanych do serwisu w krótkim czasie i zwiększenie stabilności działania skryptu.

Wynikiem warstwy wczytującej był plik `alertuj_ogloszenia_raw.csv` zawierający 240 rekordów. Plik ten stanowił podstawę do dalszego czyszczenia i przetwarzania danych.

9. Proces czyszczenia danych

Po pobraniu danych surowych wykonano etap czyszczenia i standaryzacji danych. Celem tego etapu było przekształcenie danych zapisanych w pliku `alertuj_ogloszenia_raw.csv` do bardziej uporządkowanej postaci, która mogła zostać wykorzystana w dalszej analizie oraz w bazie danych.

Dane pochodzące ze stron internetowych nie zawsze mają jednolitą strukturę. W opisach ogłoszeń mogą występować dodatkowe fragmenty tekstu, dane kontaktowe, różne sposoby zapisu miejscowości, informacje o nagrodzie albo niepełne pola. Z tego powodu przed wykonaniem analiz konieczne było przygotowanie warstwy Silver.

W procesie czyszczenia danych wykonano następujące działania:

- ▷ usunięcie zbędnych spacji i znaków końca linii;
- ▷ normalizację pól tekstowych, takich jak region, miasto, typ ogłoszenia i gatunek zwierzęcia;
- ▷ oczyszczenie pola miejscowości z fragmentów technicznych oraz nadmiarowych tekstów;
- ▷ wydzielenie roku i miesiąca publikacji na podstawie daty ogłoszenia;
- ▷ utworzenie pola informującego, czy ogłoszenie zawiera miejscowość;
- ▷ utworzenie pola informującego, czy w ogłoszeniu występuje nagroda;
- ▷ obliczenie długości opisu ogłoszenia;
- ▷ podział opisów na kategorie: krótki opis, średni opis oraz długi opis;
- ▷ obliczenie wskaźnika kompletności rekordu.

Wynikiem tego etapu był plik `alertuj_ogloszenia_clean.csv` zawierający 240 oczyszczonych rekordów. Plik ten stanowił podstawę do utworzenia bazy SQLite, zapytań SQL oraz tabel wynikowych.

Najważniejsze dodatkowe cechy utworzone w warstwie Silver przedstawia poniższa tabela.

Nowe pole	Znaczenie w analizie
<code>publication_year</code>	Rok publikacji wyodrębniony z daty ogłoszenia.
<code>publication_month</code>	Miesiąc publikacji wyodrębniony z daty ogłoszenia.
<code>animal_type_clean</code>	Ujednolicony gatunek zwierzęcia, np. Kot, Pies, Ptak, Inne.
<code>region_clean</code>	Ujednolicona nazwa województwa lub regionu.
<code>city_clean</code>	Oczyszczona nazwa miejscowości.
<code>has_city</code>	Informacja, czy rekord zawiera miejscowość.
<code>has_reward</code>	Informacja, czy w ogłoszeniu występuje nagroda.
<code>description_length</code>	Liczba znaków w opisie ogłoszenia.
<code>description_category</code>	Kategoria długości opisu.
<code>record_completeness</code>	Prosty wskaźnik kompletności najważniejszych pól rekordu.

10. Baza danych i zapytania SQL

Oczyszczone dane zostały zapisane w relacyjnej bazie danych SQLite. Zastosowanie bazy danych pozwoliło oddzielić etap przechowywania danych od etapu przygotowania wyników analitycznych oraz umożliwiło wykonanie zapytań SQL na uporządkowanym zbiorze danych.

Utworzono plik bazy danych `pet_announcements.db`, w którym znalazła się tabela `announcements`. Do tabeli załadowano 240 rekordów z pliku `alertuj_ogloszenia_clean.csv`. W tabeli zapisano zarówno dane podstawowe, jak i pola utworzone podczas czyszczenia danych, m.in. rok publikacji, miesiąc publikacji, ujednolicony gatunek zwierzęcia, miejscowość, informację o nagrodzie oraz wskaźnik kompletności rekordu.

Przykładowa struktura przepływu danych w części SQL wyglądała następująco:

```
alertuj_ogloszenia_clean.csv
→ pet_announcements.db
→ tabela announcements
→ zapytania SQL
→ pliki wynikowe sql_*.csv
```

W projekcie przygotowano kilka zapytań SQL, które odpowiadały na podstawowe pytania analityczne. Wyniki zapytań zostały zapisane w osobnych plikach CSV, aby mogły zostać później wykorzystane w raporcie Excel oraz w końcowej interpretacji wyników.

Plik wynikowy SQL	Zakres analizy
sql_animal_counts.csv	Liczba ogłoszeń według gatunku zwierzęcia.
sql_region_counts.csv	Liczba ogłoszeń według województwa lub regionu.
sql_top_cities.csv	Lista miejscowości z największą liczbą ogłoszeń.
sql_reward_counts.csv	Porównanie liczby ogłoszeń z nagrodą i bez nagrody.
sql_month_counts.csv	Liczba ogłoszeń według roku i miesiąca publikacji.
sql_description_quality.csv	Analiza kategorii długości opisów oraz średniej długości opisu.
sql_announcement_type_counts.csv	Liczba ogłoszeń według typu ogłoszenia.
sql_data_quality_summary.csv	Podsumowanie jakości danych, kompletności i dostępności wybranych pól.

Zastosowanie SQL pozwoliło zweryfikować wyniki uzyskane w warstwie Gold oraz przedstawić projekt jako system obejmujący nie tylko pliki CSV, ale również relacyjną bazę danych i kwerendy wynikowe.

Najważniejsze wyniki uzyskane na podstawie zapytań SQL potwierdziły, że w zbiorze danych znajdowało się 240 rekordów, z czego większość dotyczyła kotów i psów. Zapytania wykazały również, że 237 rekordów zawierało informację o miejscowości, a 119 ogłoszeń zawierało informację o nagrodzie.

11. Warstwa wynikowa i raport Excel

Warstwa wynikowa projektu została przygotowana w postaci zestawu plików CSV oraz zbiorczego raportu w pliku Excel. Jej zadaniem było przedstawienie danych po przetworzeniu w formie wygodnej do analizy, porównywania i prezentacji wyników końcowych.

W ramach warstwy Gold utworzono tabele agregujące dane według najważniejszych wymiarów analitycznych, takich jak gatunek zwierzęcia, województwo, miejscowość, informacja o nagrodzie, typ ogłoszenia, miesiąc publikacji oraz jakość opisu.

Dodatkowo wyniki zapytań SQL zostały zapisane w osobnych plikach CSV. Pozwoliło to porównać rezultaty przygotowane w warstwie Gold z wynikami uzyskanymi bezpośrednio z bazy danych SQLite.

Plik lub grupa plików	Rola w projekcie
alertuj_ogloszenia_raw.csv	Dane surowe pozyskane ze strony internetowej.
alertuj_ogloszenia_clean.csv	Dane oczyszczone i uzupełnione o pola analityczne.
pet_announcements.db	Relacyjna baza danych SQLite z tabelą announcements.
gold_*.csv	Tabele wynikowe utworzone na podstawie oczyszczonych danych.
sql_*.csv	Wyniki zapytań SQL wykonanych na bazie danych.
big_data_pet_announcements_report.xlsx	Zbiorczy raport Excel zawierający dane, tabele i wykresy.

Raport Excel został przygotowany jako końcowa warstwa prezentacji wyników. Główny arkusz raportu zawiera podsumowanie KPI, tabele agregacyjne oraz wykresy przedstawiające najważniejsze rezultaty analizy. Dane pomocnicze zostały wykorzystane jako źródło dla wizualizacji, natomiast raport końcowy skupia się na czytelnym przedstawieniu wniosków, a nie na ponownym prezentowaniu wszystkich danych technicznych.

12. Wyniki analizy

Analizę wykonano na zbiorze 240 rekordów pozyskanych z publicznego serwisu z ogłoszeniami dotyczącymi zaginionych zwierząt. Wyniki zostały przygotowane na podstawie warstwy Gold oraz zapytań SQL wykonanych na bazie SQLite.

Najważniejsze wyniki analizy przedstawiono poniżej.

Wskaźnik	Wartość
Liczba rekordów	240
Średnia kompletność rekordu	1.0
Rekordy z informacją o miejscowości	237
Rekordy z informacją o nagrodzie	119
Ogłoszenia bez informacji o nagrodzie	121
Ogłoszenia zaginione	233
Ogłoszenia odnalezione	2
Ogłoszenia bez jednoznacznej klasyfikacji typu	5

Największą grupę w analizowanym zbiorze stanowiły ogłoszenia dotyczące kotów. Wystąpiły one 165 razy. Ogłoszenia dotyczące psów pojawiły się 71 razy. Pozostałe gatunki występowały sporadycznie: w zbiorze odnotowano 2 ogłoszenia dotyczące ptaków, 1 ogłoszenie dotyczące innego zwierzęcia oraz 1 rekord sklasyfikowany jako inne lub brak danych.

Gatunek zwierzęcia	Liczba ogłoszeń
Kot	165
Pies	71
Ptāk	2
Inne	1
Inne / brak danych	1

Pod względem lokalizacji najwięcej ogłoszeń pochodziło z województwa mazowieckiego. W pierwszej dziesiątce znalazły się również województwa dolnośląskie, pomorskie, opolskie, małopolskie, śląskie, łódzkie oraz podkarpackie. Wynik ten może wskazywać na większą aktywność użytkowników serwisu w wybranych regionach lub na większą liczbę publikowanych tam zgłoszeń.

Województwo / region	Liczba ogłoszeń
mazowieckie	58

dolnośląskie	27
pomorskie	26
opolskie	21
małopolskie	21
śląskie	19
łódzkie	17
podkarpackie	16
kujawsko-pomorskie	9
podlaskie	8

Informacja o nagrodzie pojawiła się w 119 ogłoszeniach, natomiast w 121 przypadkach nie została podana. Oznacza to, że w badanej próbie liczba ogłoszeń z nagrodą i bez nagrody była prawie równa.

Większość opisów miała średnią lub dużą długość. W zbiorze odnotowano 134 opisy średniej długości, 82 długie opisy oraz 24 krótkie opisy. Może to oznaczać, że użytkownicy zazwyczaj podają dodatkowe informacje, takie jak wygląd zwierzęcia, miejsce zaginięcia, zachowanie lub cechy szczególne.

13. Ograniczenia projektu

Projekt został wykonany na podstawie danych pozyskanych z publicznie dostępnego serwisu internetowego. Oznacza to, że jakość wyników zależy od jakości danych opublikowanych przez użytkowników serwisu oraz od struktury technicznej strony.

Najważniejsze ograniczenia projektu są następujące:

- ▷ dane źródłowe mogą zawierać literówki, skróty, emotikony lub niestandardowe zapisy miejscowości;
- ▷ nie wszystkie ogłoszenia mają taką samą strukturę i taki sam poziom szczegółowości;
- ▷ część informacji, takich jak gatunek zwierzęcia lub typ ogłoszenia, była określana automatycznie na podstawie tekstu;
- ▷ w pojedynczych rekordach region i miejscowość mogą być niespójne, jeżeli tak zostały zapisane w źródle;
- ▷ nie analizowano zdjęć zwierząt ani dokładnych współrzędnych geograficznych;
- ▷ analiza obejmuje próbę 240 rekordów z pierwszych 20 stron serwisu, a nie całą historię wszystkich ogłoszeń;
- ▷ projekt ma charakter edukacyjny i prototypowy, dlatego nacisk położono na pełny proces przetwarzania danych, a nie na stworzenie produkcyjnego systemu monitorującego.

Pomimo wskazanych ograniczeń przygotowany system spełnia założenia projektu zaliczeniowego. Dane zostały pobrane, przetworzone, zapisane w bazie danych i przedstawione w warstwie wynikowej, co umożliwia wykonanie podstawowej analizy ogłoszeń.

14. Podsumowanie

W ramach projektu przygotowano niewielki system analityczny służący do analizy ogłoszeń dotyczących zaginionych i odnalezionych zwierząt domowych. System obejmował pełny proces pracy z danymi: od pobrania danych ze strony internetowej, przez zapis danych surowych, czyszczenie i standaryzację, aż po zapis w bazie SQLite, wykonanie zapytań SQL i przygotowanie raportu Excel.

Projekt spełnia główne wymagania dotyczące warstwy wczytującej dane, warstwy przekształceń oraz warstwy wynikowej. Dodatkowo zastosowano relacyjną bazę danych SQLite oraz zapytania SQL, co pozwoliło rozszerzyć projekt poza prostą analizę plików CSV.

Najważniejsze wyniki wskazały, że w analizowanej próbie dominowały ogłoszenia dotyczące kotów, a największa liczba ogłoszeń pochodziła z województwa mazowieckiego. Prawie połowa ogłoszeń zawierała informację o nagrodzie, a większość rekordów posiadała informację o miejscowości i opis średniej lub dużej długości.

Przygotowany projekt może stanowić podstawę do dalszego rozwoju, np. rozszerzenia liczby źródeł danych, dodania geolokalizacji, analizy tekstu opisów lub wykorzystania metod uczenia maszynowego do klasyfikacji ogłoszeń.

15. Struktura plików projektu

Końcowa wersja projektu została uporządkowana w postaci katalogów odpowiadających kolejnym elementom procesu analitycznego. Taka struktura ułatwia sprawdzenie projektu, ponieważ oddziela kod źródłowy od danych, bazy danych, wyników SQL, raportu oraz dokumentacji.

Element projektu	Rola
README.md	Krótki opis projektu, technologii, struktury plików oraz kolejności uruchamiania skryptów.
requirements.txt	Lista bibliotek Python wymaganych do uruchomienia projektu.
scripts/	Folder zawierający skrypty odpowiedzialne za pobieranie, czyszczenie, analizę i raportowanie danych.
data/	Folder z plikami CSV: danymi surowymi, oczyszczonymi oraz tabelami warstwy Gold.
database/	Folder zawierający bazę SQLite <code>pet_announcements.db</code> .
sql_results/	Folder z wynikami zapytań SQL zapisanymi w plikach CSV.
report/	Folder z końcowym raportem Excel <code>big_data_pet_announcements_report.xlsx</code> .
documentation/	Folder zawierający dokumentację projektu w formacie DOCX oraz PDF.

Najważniejsze pliki wynikowe projektu to: `alertuj_ogloszenia_clean.csv`, `pet_announcements.db` oraz `big_data_pet_announcements_report.xlsx`. Pliki te pokazują odpowiednio warstwę oczyszczonych danych, warstwę bazy danych oraz końcową prezentację wyników.

16. Instrukcja uruchomienia

Projekt można uruchomić lokalnie, korzystając z języka Python. Skrypty powinny być wykonywane w określonej kolejności, ponieważ każdy kolejny etap korzysta z plików przygotowanych w poprzednim kroku.

Krok	Skrypt	Opis działania
1	<code>01_scraper.py</code>	Pobranie danych ze strony internetowej i zapis danych surowych do pliku CSV.
2	<code>02_clean_data.py</code>	Oczyszczenie danych, standaryzacja pól i utworzenie dodatkowych cech analitycznych.

3	03_gold_tables.py	Utworzenie tabel wynikowych warstwy Gold na podstawie oczyszczonych danych.
4	04_sql_database.py	Utworzenie bazy SQLite, załadowanie danych i wykonanie zapytań SQL.
5	05_excel_report.py	Wygenerowanie końcowego raportu Excel z tabelami i wykresami.

W przypadku ponownego uruchamiania projektu zaleca się wykonywanie skryptów od początku do końca, aby wszystkie pliki wynikowe były ze sobą spójne. Jeśli dane zostały już pobrane, można rozpocząć pracę od etapu czyszczenia, korzystając z istniejącego pliku alertuj_ogloszenia_raw.csv.

Do uruchomienia projektu wymagane są biblioteki wskazane w pliku requirements.txt. Biblioteka sqlite3 jest częścią standardowej instalacji Pythona, dlatego nie wymaga osobnej instalacji.